김재광

Table of contents

3
이 책의 구성 . . . 3
대상 독자 . . . 3
유튜브 채널 . . . 3

1 1 : 4
1.1 출구조사란 무엇인가 . . . 4
1.2 2012년 강동갑 사례 . . . 4
1.2.1 데이터 . . . 4
1.2.2 단순 분석의 실패 . . . 5
1.3 인구학적 보정의 시도와 한계 . . . 5
1.3.1 성·연령대 보정이란 . . . 5
1.3.2 보정의 결과 . . . 6
1.4 통계학적 접근 . . . 7
1.4.1 기호 정의 . . . 7
1.4.2 MAR 가정과 그 한계 . . . 7
1.5 응답 거부자 예측 모형 . . . 7
1.5.1 베이즈 정리의 활용 . . . 7
1.5.2 예측 공식의 도출 . . . 8
1.6 Exponential Tilting Model . . . 8
1.6.1 로지스틱 모형 가정 . . . 8
1.6.2 β_2 의 해석 . . . 9
1.7 실증 분석 결과 . . . 9
1.7.1 강동갑 선거구 . . . 9
1.7.2 서울 전체 48개 지역구 . . . 10
1.8 마무리 . . . 10
1.9 참고문헌 . . . 11

2 2 : 12
2.1 같은 집회, 다른 숫자 . . . 12
2.2 두 가지 추산 방식 . . . 12
2.2.1 주최 측: 면적 기반 누적 인원 . . . 12
2.2.2 경찰 측: 스냅샷 기반 실시간 집계 . . . 12
2.2.3 측정 대상 자체가 다르다 . . . 13
2.3 페르미 추정법과 그 한계 . . . 13

2.4 지하철 승객 통계 이용법 13
2.4.1 논리 구조를 해부해보면 14
2.5 통계학적 접근: 현장 샘플링 14
2.5.1 아이디어 14
2.5.2 Plan A vs Plan B 14
2.5.3 추정 공식 15
2.6 분석 결과 15
2.6.1 과소추정 가능성 16
2.7 모의실험: 적정 표본 수 결정 16
2.8 마무리: 통계적 접근의 뼈대 16

3 3 : 18
3.1 작년 제주도에 외국인 관광객은 몇 명이나 왔을까 18
3.2 두 개의 데이터, 두 개의 답 18
3.2.1 서베이와 빅데이터 18
3.2.2 기초 분석의 충격 19
3.3 발상의 전환: 두 데이터를 결합하라 20
3.4 기호와 모형 20
3.4.1 세 가지 변수 20
3.4.2 두 개의 모형 21
3.5 역사적 배경: Fay-Herriot 모형 22
3.6 최적 예측 22
3.6.1 결합 공식의 도출 22
3.6.2 결합 계수의 직관 23
3.7 실증 분석 결과 24
3.7.1 시도 단위 분석 24
3.7.2 시군구 단위 분석 24
3.8 마무리 25
3.9 참고문헌 26

이 책은 유튜브 채널 통계학 산책의 강의 내용을 바탕으로 엮은 것입니다.

통계학을 전공하지 않은 독자도 읽을 수 있도록, 수식보다 직관적 이해를 우선하되 핵심 논리는 엄밀하게 서술하였습니다. 각 강의는 실제 데이터와 사례에서 출발하여, 그 뒤에 숨어 있는 통계학적 원리를 자연스럽게 드러내는 방식으로 구성하였습니다.

강의	주제
제 1 강	출구조사의 추억 — MAR 가정과 무응답 편향
제 2 강	집회 참가자수 추정 — 페르미 추정과 현장 샘플링
제 3 강	외래 관광객수 추정 — 소지역 추정과 Fay-Herriot 모형

강의가 추가될 때마다 이 목록은 업데이트됩니다.

- 통계학에 관심 있는 일반 독자
- 데이터 분석을 공부하는 학부생
- 설문·여론조사 실무자

각 챕터에 대응하는 강의 영상은 아래 재생목록에서 볼 수 있습니다. 책과 영상을 함께 활용하시면 더 효과적입니다.

▶ 통계학 산책 재생목록 바로가기

1 1 :

> “통계학은 데이터에서 진실을 끌어내는 학문이다. 그러나 진실을 끌어내려면, 먼저 데이터가 우리에게 거짓말을 하고 있다는 사실을 알아야 한다.”

1.1

선거 당일, 투표소 앞에는 방송사 조사원들이 서 있다. 투표를 마치고 나오는 유권자들에게 “어느 당에 투표하셨나요?” 라고 묻는다. 이것이 출구조사(exit poll)다.

출구조사의 목적은 하나다. 개표가 시작되기 전에 — 때로는 투표가 끝나는 순간 — 당선자를 예측하는 것이다. 방송사들이 밤새 생중계를 이어가면서 “○○ 당선 유력” 이라는 자막을 띄울 수 있는 것은 이 조사 덕분이다.

그런데 출구조사는 때로 크게 빗나간다. 왜 그럴까? 단순히 표본이 부족해서일까, 아니면 더 구조적인 이유가 있을까?

이 강의는 그 질문에서 시작한다.

1.2 2012

1.2.1

2012년 제19대 국회의원 선거, 서울 강동갑 선거구의 출구조사 자료를 살펴보자.

표 1.1: 2012 국회의원 선거 강동갑 출구조사 표본 자료

성별	연령대	새누리당	통합민주당	기타	응답 거부	총합
남성	20-29	93	115	4	28	240
남성	30-39	104	233	8	82	427

성별	연령대	새누리당	통합민주당	기타	응답 거부	총합
남성	40-49	146	295	5	49	495
남성	50-	560	350	3	174	1,087
여성	20-29	106	159	8	62	335
여성	30-39	129	242	5	70	446
여성	40-49	170	262	5	69	506
여성	50-	501	218	7	211	937
총합		1,809	1,874	45	745	4,473
개표 결과		62,489	57,909	1,624		122,022

출구조사에서 샘플로 뽑힌 사람은 총 4,473명이 선정되었다. 하지만 이 중 745명, 약 17%가 응답을 거부했다. 다른 조사와는 달리 출구조사는 참값을 알게 된다. 개표를 통해 최종 결과가 나오기 때문이다. 따라서 이 표의 맨 아래 줄의 개표 결과와 비교하는 것이 이 분석의 핵심이다.

1.2.2

출구조사 자료를 분석하여 각 정당별 최종 득표수를 예측하고자 한다. 이 경우 가장 단순한 방법은 응답 거부자 745명을 제외하고, 응답자 3,728명만으로 지지율을 계산하는 것이다.

표 1.2: 단순 분석 결과 (%)

방법론	새누리당	통합민주당	기타
무보정	48.5	50.3	1.2
참값	51.2	47.5	1.3

결과는 충격적이다. 출구조사는 통합민주당 50.3%, 새누리당 48.5%로 예측했지만, 실제 개표 결과는 새누리당 51.2%, 통합민주당 47.5%였다. 당선자가 뒤바뀐 것이다.

1.3

1.3.1 ·

응답 거부자들을 단순히 제외하는 것이 문제라면, 이들의 투표 성향을 예측해서 채워 넣으면 어떨까? 이것이 인구학적 보정의 기본 아이디어다.

"같은 성별, 같은 연령대의 응답자들과 비슷하게 투표했을 것이다" 라고 가정하고, 거부자 수에 해당 그룹의 응답자 지지율을 곱해 예측값을 만드는 것이다.

예시: 여성 50대 이상 그룹

이 그룹의 응답자는 726명(= 501 + 218 + 7)이었고, 응답 거부자는 211명이었다.

$$P(\text{새누리당} \mid \text{여성, 50대 이상}) = \frac{501}{726}$$
$$P(\text{통합민주당} \mid \text{여성, 50대 이상}) = \frac{218}{726}$$
$$P(\text{기타} \mid \text{여성, 50대 이상}) = \frac{7}{726}$$

이 비율을 거부자 211명에 적용하면:

- 새누리당 지지자 예측: $211 \times \frac{501}{726} \approx 145.6$명
- 통합민주당 지지자 예측: $211 \times \frac{218}{726} \approx 63.4$명
- 기타 예측: $211 \times \frac{7}{726} \approx 2.0$명

이렇게 채워 넣은 값을 통계학에서는 대체값(imputation value)이라고 부른다.

1.3.2

표 1.3: 인구학적 보정 결과 (%)

방법론	새누리당	통합민주당	기타
무보정	48.5	50.3	1.2
성·연령대 보정	49.0	49.8	1.2
참값	51.2	47.5	1.3

보정 후 새누리당 지지율이 48.5%에서 49.0%로 올라갔다. 조금 나아지긴 했지만, 여전히 당선자 예측은 틀렸다.

> **❗ 결론**
>
> 단순한 인구학적 변수를 이용한 보정 방법으로는 출구조사 응답 거부자의 편향을 제대로 제거할 수 없다.

1.4

1.4.1

- Y: 지지 정당 (우리가 알고 싶은 변수)
- X: 인구학적 변수 (성별, 연령대 — 관측 가능)
- R: 응답 협조 지시 변수

$$R = \begin{cases} 1 & \text{if 응답} \\ 0 & \text{if 거절} \end{cases}$$

1.4.2 MAR

성·연령대 보정이 암묵적으로 가정하는 것이 있다. 통계학에서 MAR(Missing at Random, 임의 결측)이라고 부르는 가정이다.

$$P(Y \mid X, R = 0) = P(Y \mid X, R = 1) \tag{MAR}$$

한국말로 풀면: "X가 같다면, 응답 거부자와 응답자의 투표 성향이 같다."

이 가정이 성립하면 인구학적 보정은 완벽하게 작동한다. 문제는 이 가정이 현실에서 성립하지 않을 수 있다는 것이다.

강동갑 사례에서는 아마도 이런 일이 있었을 것이다: 같은 성별, 같은 연령대이더라도 새누리당 지지자들이 응답을 더 많이 거부했다. 그 결과 응답자 중 새누리당 지지자의 비율이 실제보다 낮게 잡혔고, 집계 결과가 왜곡되었다.

1.5

1.5.1

베이즈 정리를 이용하면 $P(Y \mid X, R = 0)$과 $P(Y \mid X, R = 1)$을 각각 쓸 수 있다.

$$P(Y \mid X, R = 0) = \frac{P(R = 0 \mid X, Y)\, P(Y \mid X)}{P(R = 0 \mid X)} \tag{1}$$

$$P(Y \mid X, R=1) = \frac{P(R=1 \mid X, Y)\, P(Y \mid X)}{P(R=1 \mid X)} \tag{2}$$

식 (1)을 식 (2)로 나누면 $P(Y \mid X)$가 약분되어 다음을 얻는다.

$$\frac{P(Y \mid X, R=0)}{P(Y \mid X, R=1)} = \underbrace{\frac{P(R=0 \mid X, Y)}{P(R=1 \mid X, Y)}}_{\text{Nonresponse odds}} \cdot \underbrace{\frac{P(R=1 \mid X)}{P(R=0 \mid X)}}_{Y\text{와 무관}} \tag{3}$$

두 번째 항은 Y와 무관하다. 따라서 응답 거부자와 응답자의 투표 성향 차이를 결정하는 것은 오직 첫 번째 항, Nonresponse odds다.

1.5.2

Nonresponse odds 함수를 다음과 같이 정의하자.

$$O(X, Y) \equiv \frac{P(R=0 \mid X, Y)}{P(R=1 \mid X, Y)}$$

그러면 식 (3)으로부터 다음의 예측 공식을 유도할 수 있다.

$$P(Y=y \mid x, R=0) = P(Y=y \mid x, R=1) \cdot \frac{O(x, y)}{E[O(x, Y) \mid x, R=1]} \tag{4}$$

응답 거부자의 투표 성향은, 응답자의 투표 성향을 출발점으로 삼아 Nonresponse odds 비율만큼 재조정한 것이다.

1.6 Exponential Tilting Model

1.6.1

응답 협조 확률이 로지스틱 회귀 모형을 따른다고 가정하자.

$$P(R=1 \mid X, Y) = \frac{\exp(\beta_0 + \beta_1 X + \beta_2 Y)}{1 + \exp(\beta_0 + \beta_1 X + \beta_2 Y)}$$

이것을 식 (4)에 대입하면 β_0과 β_1 항이 상쇄되어 다음을 얻는다.

$$P(Y = y \mid x, R = 0) = P(Y = y \mid x, R = 1) \cdot \frac{\exp(-\beta_2 y)}{E[\exp(-\beta_2 Y) \mid x, R = 1]} \tag{5}$$

핵심은 β_2 하나다. 이 모형은 @kim2011 에서 처음 소개되었으며, Exponential tilting model이라고 부른다.

1.6.2

β_2의 값	의미	편향 방향
$= 0$	MAR 성립, 인구학적 보정으로 충분	없음
> 0	새누리당 지지자가 응답을 더 잘 함	새누리당 과대 추정
< 0	새누리당 지지자가 응답을 더 많이 거부	새누리당 과소 추정

> **Note**
>
> 2012년 강동갑의 상황은 $\beta_2 < 0$의 경우였다. 이것이 인구학적 보정을 아무리 해도 편향이 제거되지 않았던 근본적인 이유다.

1.7

1.7.1

@riddles2016 은 식 (5)의 β_2를 EM 알고리즘으로 추정하는 방법론을 개발하고 강동갑 데이터에 적용했다.

표 1.4: 강동갑 출구조사 분석 결과 (%)

방법론	새누리당	통합민주당	기타
무보정	48.5	50.3	1.2
성·연령대 보정	49.0	49.8	1.2
제안된 방법론	51.0	47.7	1.2
참값	51.2	47.5	1.3

제안된 방법론은 참값 51.2%에 오차 0.2%포인트 이내로 접근했다.

1.7.2 48

표 1.5: 서울 전체 출구조사 분석 결과 (48개 지역구, 1위 예측 횟수)

방법론	새누리당	통합민주당	기타
무보정	10	36	2
성·연령대 보정	10	36	2
제안된 방법론	15	29	4
참값	16	30	2

무보정과 인구학적 보정은 결과가 동일했다. 두 방법 모두 MAR 가정에 의존하기 때문이다. 제안된 방법론은 참값(새누리당 16석)에 훨씬 가까운 15석을 예측했다.

1.8

이 연구의 출발점은 저자의 2006년 출구조사 자문단 참여였다. 당시는 연세대 응용통계학과에 근무할 시절이라 한국의 기관들과의 협력이 수월했다. SBS 방송사의 연락으로 자문단에 참여하게 되었는데 이번 무응답 문제에 대해 알게 되었다. MAR 가정이 성립하지 않는다는 것을 알고 이를 어떻게 해결할수 있을지를 고민하기 시작했다.

그후 미국으로 이민을 오게 되었고 당시의 문제를 좀더 깊이있게 고민할 기회가 생겼다. 그 연구 결과는 @kim2011 과 @wang2014 로 이어졌다. 두 논문은 저자의 논문 중 가장 많이 인용되는 논문이 되었고, MAR이 성립하지 않는 어려운 상황에서도 합리적인 추론이 가능하다는 돌파구를 제시했다는 점에서 의미가 있다.

마지막으로 한 가지 생각을 공유하고 싶다.

출구조사의 성공을 "1등을 맞추었느냐"로 판단하는 것은 방송사의 관점이다. 통계학자의 관점은 다르다.

> **통계학자의 관점**
>
> 1등을 틀리더라도 오차가 1~2%인 예측이, 1등을 맞추더라도 오차가 10% 이상인 예측보다 통계학적으로 훨씬 바람직하다.
> 단순히 결과를 맞추는 것보다, 결과를 얻어내는 과정이 합리적인가를 더 중요하게 봐야 한다.

1.9

2 2 :

“데이터는 답을 주지 않는다. 올바른 질문을 던질 때 비로소 답이 보인다.”

2.1 ,

2016년 11월 12일, 광화문 일대에서 대규모 촛불집회가 열렸다. 그날 연합뉴스의 헤드라인은 이렇게 전했다.

“사상 최대 촛불집회… 주최측-경찰 추산인원 차이 여전”

주최 측은 100만 명, 경찰은 26만 명. 같은 집회, 같은 날, 같은 장소를 두고 네 배에 가까운 차이가 났다. 왜 그럴까? 그리고 어느 쪽이 더 맞을까?

이 강의는 그 질문에서 시작한다.

2.2

2.2.1 :

주최 측의 방식은 두 단계로 이루어진다.

첫째, 집회 장소의 전체 면적(m^2)을 구한다. 둘째, 단위 면적당 밀집 인원을 곱한다. 여기에 시간대별 유동 인구를 누적하여 집회 전체 시간 동안 현장을 거쳐 간 총인원을 발표한다.

2.2.2 :

경찰 측은 집회가 가장 밀집된 특정 시점을 기준으로, 경찰이 통제 가능한 주요 거점 위주로 인원을 집계한다.

2.2.3

두 방식의 근본적인 차이는 무엇을 세느냐에 있다. 주최 측은 집회 시간 전체를 거쳐 간 누적 인원을, 경찰 측은 특정 시점에 한 곳에 있는 동시 인원을 측정한다. 두 수치가 다른 것은 당연하다.

2.3

면적 기반 집계를 페르미 추정법이라 부른다. 공식은 간단하다.

$$\text{전체 인원} = \text{전체 면적} \times \text{단위 면적당 밀도}$$

문제는 밀도 설정에 있다. 주최 측은 $1m^2$당 3~4명으로, 경찰 측은 1~2명으로 가정했다. 가정 하나의 차이가 최종 추정치를 몇 배나 벌려놓는다.

페르미 추정은 빠르고 직관적이지만, 핵심 가정이 주관적 판단에 의존한다는 근본적인 한계를 가진다.

2.4

페르미 추정의 한계를 보완하려는 시도 중 하나가 지하철 승객 통계를 활용하는 방법이다. 2016년 11월 13일 연합뉴스는 다음과 같이 보도했다.

> 광화문광장과 서울광장 인근 지하철역 12곳의 집회 당일 하차 승객은 86만 4,596명으로, 전년도 같은 요일 평균보다 51만 4,940명 많았다. 지하철 수송 분담률(약 39%)을 고려하면 집회 참석자는 총 132만 명으로 추산된다.

공식으로 쓰면 이렇다.

$$514{,}940 \div 0.39 \approx 1{,}320{,}359$$

2.4.1

이 추론에는 두 단계가 있다.

1. 전체 하차 승객 86만 명 → 집회 참석 지하철 이용자 51만 5천 명 (전년 대비 증가분)
2. 집회 참석 지하철 이용자 51만 5천 명 → 전체 집회 참석자 132만 명 (수송분담률 적용)

두 번째 단계에서 핵심 가정이 등장한다. 집회 참석자의 39%가 지하철을 이용했다는 것이다. 그런데 이 39%는 2014년의 서울시 전체 평균 수송분담률이다. 대규모 집회가 열리는 날, 많은 사람이 대중교통을 선택한다. 이 날의 지하철 이용률이 평상시와 같다는 가정은 현실적으로 적절하지 않다.

> **❗ 핵심 문제**
>
> 평상시의 지하철 수송분담률 39%를 집회 당일에 그대로 적용하는 것은 타당하지 않다. 이 비율 자체를 데이터로부터 추정해야 한다.

2.5 :

2.5.1

해결책은 명쾌하다. 집회 당일의 지하철 이용 비율을 현장에서 직접 조사하여 추정 공식에 반영하자는 것이다.

2.5.2 Plan A vs Plan B

1,000명을 조사할 예산 하에서 두 가지 플랜이 검토되었다.

Plan A: 조사원 전원을 집회 현장에 배치하여 참석자에게 이동 수단을 묻는다. 모수는 하나: $P(X = 1 \mid Y = 1)$ (집회 참석자 중 지하철 이용 비율).

Plan B: 조사원을 두 집단으로 나눈다. 한 팀은 지하철 역에서 하차객에게 집회 참석 여부를 묻고($P(Y = 1 \mid X = 1)$ 추정), 다른 팀은 집회 현장에서 참석자에게 이동 수단을 묻는다 ($P(X = 1 \mid Y = 1)$ 추정). 두 모수를 동시에 추정한다.

최종적으로 Plan B가 채택되었다. 두 모수를 동시에 추정함으로써 이론적으로 더 효율적인 추정이 가능하기 때문이다.

2.5.3

모집단을 집회 참석 여부 Y와 지하철 이용 여부 X로 분류하면 다음 표를 얻는다.

집회 참석	지하철 이용 $(X=1)$	다른 교통수단 $(X=0)$	총합
참석 $(Y=1)$	N_{11}	N_{01}	N_{+1}
불참석 $(Y=0)$	N_{10}	N_{00}	N_{+0}
총합	N_{1+}	N_{0+}	N_{++}

우리의 목표는 N_{+1}, 즉 집회 총 참석자 수를 추정하는 것이다. 다음 등식을 이용한다.

$$N_{+1} = N_{++} \cdot P(Y=1) = N_{++} \cdot P(X=1) \cdot \frac{P(Y=1 \mid X=1)}{P(X=1 \mid Y=1)}$$

$N_{++} \cdot P(X=1) = N_{1+}$ (지하철 총 하차 승객수)는 서울시 공식 통계로 알 수 있다. 따라서:

$$\boxed{N_{+1} = N_{1+} \cdot \frac{P(Y=1 \mid X=1)}{P(X=1 \mid Y=1)}}$$

두 비율 $P(Y=1 \mid X=1)$과 $P(X=1 \mid Y=1)$을 현장 조사로 추정하면 된다.

2.6

집회 참석	지하철 이용	다른 교통수단	총합
참석	55만	23만	78만
불참석	35만	—	—
총합	90만	—	—

Plan B는 ratio 추정의 형태이므로 신뢰구간 계산도 가능하다는 장점이 있다.

흥미로운 뒷이야기가 있다. 이 조사를 의뢰한 언론사는 비용을 지불하고도 여론을 의식하여 최종 결과를 공개하지 않았다. 통계 결과의 투명한 공개가 얼마나 중요한지를 역설적으로 보여주는 사례다.

2.6.1

약 78만 명이라는 추정치는 실제보다 다소 과소추정되었을 가능성이 있다. Plan B에서 지하철 역의 혼잡한 환경은 조사 원칙대로 인터뷰를 진행하기 어렵게 만들었고, 이로 인한 비표본 오차(non-sampling error)가 결과에 영향을 미쳤을 것으로 판단된다.

이는 Plan A와 Plan B의 트레이드오프를 다시 생각하게 한다. Plan A는 조사원을 한 곳에만 배치하므로 조사원 관리가 용이하고 비표본 오차를 줄일 수 있다. 이론적으로 우수한 설계가 현장에서 반드시 최선의 결과를 보장하지는 않는다.

2.7 :

방법론의 정확성을 검증하기 위해 모의실험을 실시했다. 모집단을 설정한 뒤 반복 샘플링을 통해 집회 참석자 수 $\hat{\theta}$를 추정하고, 그 오차를 RMSE로 측정했다.

$$\mathrm{RMSE}(\hat{\theta}) = \left[\mathbb{E}\left\{(\hat{\theta} - \theta)^2\right\}\right]^{1/2}$$

결과는 명확했다. RMSE는 표본 크기가 커질수록 단조 감소하며, 총 표본 크기 약 1,000명 수준에서 RMSE가 5% 임계선 아래로 내려온다. 1,000명이라는 조사 예산이 실용적으로 충분한 정확도를 확보하기 위한 적절한 수치임이 확인된 것이다.

2.8 :

페르미 추정은 거친 근사치를 제공한다. 그러나 현대 사회에서는 지하철 통계처럼 다양한 보조 정보를 활용할 수 있다. 통계학은 이 보조 정보를 주관적 판단이 아닌 데이터로부터 추정된 모형을 통해 calibration한다. 이것이 핵심이다.

통계적 접근의 세 가지 뼈대:

1. 유용한 보조정보
2. 통계적 모형
3. 모형의 모수를 데이터로부터 추정

통계학자의 관점

통계적 방법은 설명 가능하고 투명하다. 물론 비용이 수반된다 — 데이터 수집 비용과 전문가 활용 비용 모두. 결국 통계 품질에 대한 의지가 그 비용을 지불하는 결정으로 이어진다.
그리고 그 의지는 정치적 중립성에 대한 의지와 긴밀히 연결된다. 통계는 사회적 신뢰를 기반으로 하는 일종의 공공재다.

3 3 :

> “데이터가 하나뿐일 때 우리는 그것을 믿을 수밖에 없다. 데이터가 두 개일 때 비로소 통계학이 시작된다.”

3.1

단순한 질문이다. 어딘가에 답이 있을 것 같고, 실제로 한국관광공사 같은 기관에서는 매년 이런 통계를 발표한다. 그런데 이 숫자가 어떻게 만들어지는지 들여다보면 이야기가 달라진다.

우리는 이번 강의에서 외래관광객 실태조사라는 구체적인 사례를 통해, 현대 통계학의 중요한 갈래 중 하나인 소지역 추정(small area estimation)을 살펴볼 것이다. 서로 다른 두 자료가 다른 답을 내놓을 때, 우리는 어떻게 진실에 접근할 수 있을까?

3.2 ,

3.2.1

한국관광공사는 외국인 관광객 통계를 만들기 위해 두 가지 종류의 자료를 수집한다.

첫째는 외래관광객 실태조사, 즉 서베이 자료다. 공항에서 출국하는 외국인을 대상으로 어느 지역을 방문했는지, 얼마나 머물렀는지 등을 설문한다. 우리가 통계라고 하면 흔히 떠올리는 전통적 방식이다.

둘째는 KT 핸드폰 로밍 데이터다. 외국인이 한국에 입국하면 대부분 자국 통신사의 로밍 서비스를 이용하는데, 이때 기지국 위치 정보가 자동으로 기록된다. 누가 어느 지역에 언제 있었는지가 대량으로 집계된다. 이른바 빅데이터다.

3.2.2

2016년 중국인 관광객에 대해 두 자료를 시도별로 나란히 놓아보자.

표 3.1: 2016년 중국인 관광객 수 (단위: 천 명)

지역	서베이 값	KT 자료값	T-통계량
서울	5,953	4,945	5.91
부산	390	357	0.40
대구	35	87	-2.01
인천	354	1,335	-11.95
광주	18	30	-0.75
대전	33	32	0.03
울산	0	35	—
경기	624	1,216	-5.68
강원	228	128	1.54
충북	13	125	-6.67
충남	38	78	-1.54
전북	56	50	0.17
전남	44	111	-2.31
경북	61	83	-0.72
경남	44	83	-1.37
제주	2,818	2,009	4.39

숫자가 놀랄 만큼 다르다. 서울은 서베이가 100만 명 이상 많고, 인천은 KT 자료가 거의 네 배나 많다. 제주는 서베이가 훨씬 크고, 충북은 KT가 열 배 가까이 크다.

어느 쪽이 맞는 것일까?

사실 둘 다 틀렸을 수 있다. 정확히 말하면, 둘 다 나름의 오차를 가지고 있다는 것이 통계학자의 관점이다. 다만 그 오차의 성격이 서로 다르다.

- 서베이는 표본 오차(sampling error)를 가진다. 모든 관광객을 조사한 것이 아니라 일부만 뽑아서 조사했기 때문이다. 표본을 다시 뽑으면 값이 또 달라지는, 무작위 변동에 의한 오차다.
- KT 빅데이터는 겉보기에는 전수조사처럼 보이지만 실제로는 그렇지 않다. KT 가입자만 잡히며, 타 통신사 로밍 고객은 빠지고, 여러 기지국 신호가 겹쳐 중복 집계되기도 하며, 공항에 잠시 내렸다 간 환승객까지 포함되는 문제가 있다. 이렇게 한쪽으로 치우쳐서 나타나는 체계적 오차를 통계학에서는 정보 편향(information bias)이라고 부른다.

두 오차의 성격이 다르다는 점이 중요하다. 표본 오차는 표본을 늘리면 줄어들지만, 편향은 데이터를 아무리 많이 모아도 저절로 없어지지 않는다. 인천 사례가 전형적이다. KT는

수백만 건의 데이터를 가지고 있지만, 그 많은 데이터가 전부 같은 방향으로 부풀려져 있다. 공항에 기지국 신호가 잡힌 사람을 모두 인천 방문객으로 집계하기 때문이다.

3.3 :

"둘 다 쓰고 싶은데 어떻게 하면 될까요?"

한국관광공사 통계 담당자가 어느 날 저자를 찾아와서 던진 질문이 바로 이것이었다. 당시 저자는 카이스트에서 교수로 재직 중이었고, 그 담당자는 이 문제를 풀 수 있는 사람을 수소문한 끝에 저자를 찾아왔다. 소지역 추정 분야를 연구해온 통계학자를 찾고 있었던 것이다.

담당자의 고민은 명확했다. 한쪽을 버릴 수가 없었기 때문이다. 서베이 자료는 정부가 공식 통계로 인정하는 신뢰도를 가지고 있고, KT 자료는 서베이에서 놓친 풍부한 정보를 담고 있다. 어느 하나만 선택하는 것은 나머지 하나를 버리는 일이었다.

그래서 문제는 이렇게 재정의된다.

> 한쪽을 버릴 것이 아니라, 두 데이터를 결합할 수는 없을까?

각자 다른 약점을 가진 두 정보원이 있을 때, 이들을 잘 섞으면 각각보다 나은 추정값을 만들 수 있다는 아이디어다. 이 발상에서 출발하는 것이 바로 소지역 추정(Small Area Estimation)이다.

"소지역" 이라는 말에서 "소(小)" 는 크기가 작다는 뜻이 아니라 서베이 표본이 충분히 확보되지 않은 단위라는 뜻이다. 외래관광객 실태조사 표본을 16개 시도에 흩뿌려 놓으면 지역별 표본이 매우 적어지고, 서베이 추정값의 오차가 너무 커져서 쓸모가 없어진다. 바로 이때 다른 데이터의 도움을 받자는 것이다.

3.4

3.4.1

각 지역 i에 대해 다음 세 가지 양을 생각하자.

- Y_i: 지역 i의 실제 방문자 수. 우리가 진짜 알고 싶은 값이지만 관측할 수 없다.
- $\hat{Y}_i$: 서베이에서 얻은 Y_i의 추정값. 표본 오차가 있다.
- X_i: KT 빅데이터 값. 정보량은 풍부하지만 정보 편향이 있다.

우리의 목표는 이것이다: $\hat{Y}_i$와 X_i를 이용하여 Y_i를 알아내자.

> **ℹ 예측(prediction)과 추정(estimation)의 구별**
>
> 이런 식으로 관측되지 않은 확률변수의 값을 다른 관측값을 이용해 알아내는 것을 통계학에서는 예측(prediction)이라고 부른다. 비슷한 용어인 추정(estimation)과 구별해야 한다.
>
> - 추정(estimation): 고정된 미지의 모수(parameter)를 알아내는 것. 예를 들어 모집단 평균 μ를 알아내는 일.
> - 예측(prediction): 관측되지 않은 확률변수(random variable)의 값을 알아내는 것. 예를 들어 내일의 기온, 또는 여기서의 Y_i.
>
> 여기서 Y_i를 확률변수로 보는 이유는 뒤에 나올 구조 오차 모형에서 Y_i가 e_i라는 무작위 항을 가진 것으로 가정되기 때문이다.

3.4.2

소지역 추정에서는 두 가지 모형을 동시에 세운다.

첫째, 표본 오차 모형(sampling error model):

$$\hat{Y}_i = Y_i + u_i, \quad u_i \sim N(0, V_i)$$

서베이 값은 참값에 랜덤한 오차가 더해진 것이다. 여기서 V_i는 서베이 설계로부터 계산 가능하다.

둘째, 구조 오차 모형(structural error model):

$$Y_i = \beta X_i + e_i, \quad e_i \sim N(0, \sigma^2 X_i)$$

참값은 빅데이터 값에 비례하되 약간의 모형 오차가 있다. 이 모형의 주인공은 β다. β는 빅데이터의 편향을 보정하는 눈금자(calibration multiplier) 역할을 한다. 예를 들어 $\hat{\beta} = 0.4$라면 "KT 데이터는 참값의 2.5배 정도 부풀려져 있다"고 해석할 수 있다.

3.5 : Fay-Herriot

이 모형의 뿌리는 1970년대 미국으로 거슬러 올라간다.

미국 연방정부는 교육 불평등을 줄이기 위해 가난한 지역일수록 초중고 보조금을 더 많이 배분한다는 원칙을 세우고 있었다. 이 원칙을 실현하기 위해 미국 의회는 SAIPE(Small Area Income and Poverty Estimates) 프로그램을 법안으로 통과시켰다. "각 학군별로 소득 및 빈곤 통계를 매년 산출하여, 이를 근거로 보조금을 차등 배분하라"는 것이 법적 명령이 된 것이다.

이 법안은 미국 인구통계국(Census Bureau)에 엄청난 숙제를 안겨주었다. 미국 전역의 학군은 1만 개가 넘는데, 그 모든 학군에 대해 매년 소득 통계를 내야 했다. 문제는 두 가지였다.

- 센서스(인구조사)는 10년에 한 번만 이루어지므로 센서스 자료는 시간이 지날수록 오래된 값이 된다.
- 매년 하는 서베이는 작은 지역 단위로 내려가면 표본이 적어 오차가 너무 크다.

이 난제를 풀기 위해 1979년, 두 명의 Census Bureau 통계학자 Robert Fay와 Roger Herriot이 나섰다〔@fay1979〕. 그들의 제안은 다음과 같았다.

> 센서스 자료(X_i)는 시점이 오래되었지만 정확한 기준점을 제공한다. 서베이 자료($\hat{Y}_i$)는 최신이지만 오차가 크다. 두 정보를 섞자.

이것이 Fay-Herriot 모형이다. 이 모형 덕분에 SAIPE 프로그램은 실제로 작동 가능한 통계 체계가 되었고, 정부 기관이 통계 모형을 정책에 직접 반영한 세계 최초의 사례로 기록되었다. 의회의 법안이 행정부에 숙제를 안기고, 그 숙제가 통계학자들에게 새로운 이론을 만들게 했으며, 그 이론이 거꾸로 정책의 근거가 된 것이다.

3.6

3.6.1

우리의 목표는 $\hat{Y}_i$와 X_i를 결합하여 Y_i를 예측하는 것이었다.

두 모형을 결합하면 $\hat{Y}_i$의 주변 분포(marginal distribution)를 유도할 수 있다.

$$\hat{Y}_i = \beta X_i + \underbrace{e_i}_{\text{model error}} + \underbrace{u_i}_{\text{sampling error}}$$

두 오차 e_i와 u_i가 서로 독립이고 정규분포를 따른다고 가정하면,

$$\hat{Y}_i \sim N\left(\beta X_i,\ \sigma^2 X_i + V_i\right) \tag{1}$$

식 (1)에 최대우도 추정법(maximum likelihood method)을 적용하면 $\theta = (\beta, \sigma^2)$을 데이터로부터 추정할 수 있다.

이렇게 얻은 모수 추정치를 바탕으로, Y_i의 최적 선형 불편 예측량(best linear unbiased predictor, BLUP)은 다음과 같은 형태로 유도된다.

$$\hat{Y}_i^* = \alpha_i \hat{Y}_i + (1 - \alpha_i) X_i \hat{\beta} \tag{2}$$

여기서 결합 계수 α_i는

$$\alpha_i = \frac{V(e_i)}{V(u_i) + V(e_i)} = \frac{\sigma^2 X_i}{V_i + \sigma^2 X_i}$$

이다.

3.6.2

식 (2)는 두 추정량의 가중평균이다. 오른쪽 항 $X_i\hat{\beta}$는 "KT 값에 보정 계수를 곱한 것", 즉 모형으로부터 만들어진 합성 추정량(synthetic estimator)이다. 왼쪽 항 $\hat{Y}_i$는 서베이로부터 얻은 직접 추정량(direct estimator)이다.

이렇게 성격이 서로 다른 두 추정량을 결합한 형태의 추정량을 통계학에서는 복합 추정량(composite estimator)이라고 부른다. 한 종류의 정보만으로는 부족할 때 여러 정보원을 복합적으로 활용한다는 뜻에서다. 즉 최적 예측치 $\hat{Y}_i^*$는 직접 추정량과 합성 추정량의 복합 추정량이다.

결합 계수 α_i의 해석은 직관적이다.

- $V(u_i)/V(e_i) \to 0$이면 $\alpha_i \to 1$이 되어 $\hat{Y}_i^* \to \hat{Y}_i$. 즉 서베이 오차가 작으면 서베이 값을 그대로 믿는다.
- $V(e_i)/V(u_i) \to 0$이면 $\alpha_i \to 0$이 되어 $\hat{Y}_i^* \to X_i\hat{\beta}$. 즉 서베이 오차가 크면 모형 기반 합성값에 의존한다.

불확실한 쪽에 덜 기대고, 확실한 쪽에 더 기대는 것이다. 당연한 이치이지만, 이 "당연함"을 수식으로 엄밀하게 표현한 데 소지역 추정의 가치가 있다.

3.7

3.7.1

앞의 모형을 2016년 중국인 관광객 자료에 적용하면 다음과 같은 결과를 얻는다.

표 3.2: 시도 단위 분석 결과 (단위: 천 명)

지역	직접 추정 $\hat{Y}_i$	간접 추정 $X_i\hat{\beta}$	결합 계수 α_i	최적 추정값 $\hat{Y}_i^*$	상대 MSE (%)
서울	5,953	3,589	0.993	5,936	99.6
부산	390	259	0.755	358	87.4
대구	35	64	0.663	45	82.1
인천	354	969	0.978	367	99.0
광주	18	22	0.354	21	59.5
대전	33	23	0.222	26	47.1
울산	0	25	0.000	25	—
경기	624	883	0.958	635	97.9
강원	228	93	0.392	146	62.6
충북	13	91	0.904	21	95.1
충남	38	57	0.604	45	77.7
전북	56	36	0.286	42	53.5
전남	44	81	0.712	54	84.4
경북	60	61	0.524	60	72.4
경남	44	60	0.582	51	76.3
제주	2,818	1,458	0.953	2,754	97.7

상대 MSE: 직접 추정량의 MSE 대비 최적 예측값의 MSE 비율

서울은 $\alpha_i = 0.993$로 거의 1에 가깝다. 서울은 표본이 커서 서베이 값을 거의 그대로 믿는다는 뜻이다. 반면 울산은 $\alpha_i = 0$이다. 서베이 응답자가 0명이었기 때문에 서베이를 전혀 신뢰할 수 없어 모형에만 의존한다. 광주와 대전 같은 중간 규모 지역에서는 α_i가 0.2~0.4 정도로 나와 두 자료를 적절히 섞는다.

마지막 열의 상대 MSE는 이 방법이 얼마나 효율적인지를 보여준다. 특히 표본이 작은 지역일수록 소지역 추정이 서베이 단독 추정 대비 큰 개선을 가져온다. 대전의 경우 오차 분산이 절반 이하로 줄었다.

3.7.2

시도보다 한 단계 더 내려가면 서베이 표본은 더욱 작아지고, 소지역 추정의 위력은 더 뚜렷해진다.

표 3.3: 시군구 단위 분석 결과 (강원-충남 일부, 단위: 백 명)

지역	직접 추정	간접 추정	결합 계수	최적 추정값
강릉	245	119	0.147	138
속초/양양	50	579	0.854	127
동해/삼척	130	144	0.159	141
춘천	1,727	859	0.311	1,128
평창	79	388	0.637	191
정선	30	82	0.191	72
태안	89	46	0.120	51
천안	239	272	0.672	250
보령	23	24	0.101	24
금산	23	16	0.047	16
아산	129	145	0.505	137

속초/양양은 서베이가 5천 명, KT가 5만 8천 명으로 열 배 이상 차이가 난다. 최적 추정값은 1만 3천 명으로 KT 쪽에 많이 의존했다 ($\alpha_i = 0.854$). 반면 춘천은 서베이가 17만 3천 명, KT가 8만 6천 명으로 서베이 쪽이 크고, 최적 추정값 약 11만 3천 명은 서베이를 많이 반영했다 ($\alpha_i = 0.311$).

지역마다 두 자료의 신뢰도가 다르고, 모형은 그에 맞추어 자동으로 가중치를 조절한다.

3.8

전통적으로 공식 통계는 서베이에 의존해왔다. 그러나 최근 상황은 빠르게 바뀌고 있다.

한편으로는 위기다. 응답률은 점점 떨어지고 — 제1강의 출구조사 사례에서 이미 보았듯이 — 조사 예산은 줄어들고 있다. 다른 한편으로는 기회이기도 하다. 핸드폰 로밍 데이터, 신용카드 거래 데이터, 검색어 데이터 등 예전에는 상상할 수 없던 방대한 자료가 실시간으로 쏟아진다.

하지만 빅데이터를 그대로 쓸 수는 없다. 정보 편향이 있기 때문이다. 반대로 서베이만 고집하기도 어렵다. 표본이 부족하기 때문이다.

소지역 추정은 이 두 세계를 연결하는 다리다. 서베이를 학습 자료로 삼아 빅데이터를 보정하고, 동시에 빅데이터의 풍부한 정보량을 활용하여 서베이의 한계를 극복한다. 보정된 빅데이터 자료를 그대로 통계로 사용하는 합성 데이터 방식(synthetic data method)은 모형에 지나치게 의존하므로, 이를 보완하기 위해 직접 추정량과 결합한 복합 추정량을 사용하는 것이 소지역 추정의 핵심이다.

결론

좋은 통계는 하나의 완벽한 데이터에서 나오지 않는다. 서로 다른 결함을 가진 여러 데이터를 적절한 가중치로 결합할 때 비로소 합리적인 추정이 가능하다.

통계학자의 관점

편향된 자료라고 해서 버릴 일이 아니며, 표본이 작다고 해서 포기할 일도 아니다. "어떤 정보를 얼마나 믿을 것인가"를 결정하는 것이 통계학자의 일이다.
소지역 추정은 이 판단을 수식으로 엄밀하게 표현하는 방법을 제공한다. 불확실한 쪽에는 덜 기대고, 확실한 쪽에는 더 기댄다. 그리고 그 "얼마나"의 비율을 자료 스스로가 말하게 한다.

3.9